

MATERIAL DO ALUNO**M4 — Instrumento Operacional****Folha de trabalho da investigação final**

v2.1 — APROVADO E VIGENTE

Preencha este instrumento a partir do que foi observado no M16 v1.3.

1. Da evidência à questão experimental

Campo	Registro do grupo
Opção do grupo	P03
Observação de origem no M16	No M16, B (1,2) teve acurácia 0,960 e A (1,1) teve 0,935. As duas erraram os mesmos 29 textos. Na matriz de B, 14 dos 30 erros ficaram em 3 dos 10 pares de setores (biblioteca×secretaria, financeiro×secretaria e coordenação×suporte). Os casos que olhamos tinham dois pedidos.
Tipo de evidência	ambas erraram
Hipótese ou expectativa	A gente esperava encontrar mais casos difíceis em alguns pares de setores, principalmente os que envolvem secretaria acadêmica e coordenação×suporte, em vez de eles aparecerem de forma parecida em todos os pares.
Trilha escolhida	A - pares de setores mais confundidos
Questão escolhida ou adaptada	Quais pares de setores tiveram mais casos difíceis no P03 (erros das duas representações) e o que eles têm em comum?
Justificativa com base no M16	Na validação, 14 dos 30 erros de B (47%) ficaram em 3 dos 10 pares. Como esses pares foram escolhidos depois de vermos os erros, consideramos isso apenas como um indício e usamos dados novos para conferir.

Antes de ampliar o corpus: confirme com o professor que sua trilha/questão não se sobrepõe à de outro grupo do mesmo corpus-base.

2. Planejamento da extensão

Campo	Registro do grupo
Quantidade de novos exemplos	120 exemplos (mínimo 80)
Tipos de exemplos necessários	Fizemos 60 exemplos com um pedido, 42 com dois pedidos e marcador de prioridade e 18 com dois pedidos sem marcador. Os exemplos foram divididos em 3 pares: biblioteca×secretaria, financeiro×secretaria e coordenação×suporte, com 40 exemplos de cada. A secretaria ficou com 40 exemplos e os outros setores com 20, porque ela aparece em dois pares.
Origem/proveniência	Arquivo P03_extensao_TrilhaA.csv, separado do corpus-base. Os textos foram gerados com o Claude a partir das instruções do grupo, sem dados pessoais. A coluna de origem do CSV registra essa informação em cada linha.
Critério de rotulagem	Setor_destino = setor do pedido principal. Havendo marcador de prioridade, vale o pedido marcado. Caso sem marcador, vale o primeiro pedido (Exemplo conferido em EXT-010 e EXT-013)
Como tratar ambiguidades	Os 18 casos com ambiguidade foram mantidos no conjunto e analisados separadamente, em vez de serem descartados.
Uso de IA, se houver	O Claude gerou os 120 exemplos da extensão a partir das instruções do grupo. Depois, nós revisamos os rótulos e marcamos isso na coluna revisado_pelo_grupo do CSV.

→ Manter a extensão separada do corpus-base bruto.

→ Evitar dados pessoais, sensíveis ou material sem autorização.

→ Congelar pergunta, preparação, representação, classificador e configuração antes de consultar o teste.

3. Resultado da investigação

Campo	Registro do grupo
Resultado na validação M3	B (1,2): acurácia 0,960, F1-macro 0,959 e 30 erros em 750 textos. A (1,1): acurácia 0,935 e F1-macro 0,934.
Resultado no teste final	B congelado: acurácia 0,951, F1-macro 0,949 e 37 erros em 750 textos. Menor recall: biblioteca (0,885).
Resultado na extensão/conjunto de desafio	Acurácia 0,683 (82 de 120). Um pedido: 53 de 60. Dois pedidos com marcador: 21 de 42. Dois pedidos sem marcador: 8 de 18. F1-macro: 0,677 e 38 erros.
Principal erro ou caso difícil	O principal problema apareceu nos textos com dois pedidos de setores diferentes. Um exemplo da validação foi um texto com boleto + base de periódicos, cujo rótulo era biblioteca, mas A e B previram financeiro. No teste, 9 dos 37 erros ficaram nos 3 pares analisados na validação.
O que mudou?	O pipeline não mudou, porque B ficou congelado e não fizemos um novo ajuste. O que mudou foi o resultado: a concentração nos 3 pares, que tinha sido 14 de 30 erros na validação, não apareceu da mesma forma no teste, em que foram 9 de 37.
A questão experimental foi respondida?	Parcialmente. Não encontramos uma concentração clara em pares específicos, mas percebemos que os textos com dois pedidos foram os mais difíceis. Como a extensão tem somente esses 3 pares, não foi possível comparar com outros pares.
Conclusão	A hipótese ficou enfraquecida. A concentração nos 3 pares não se repetiu no teste. O que continuou aparecendo foi a dificuldade com textos que tinham dois pedidos.

Campo	Registro do grupo
Limitação principal	A principal limitação é que a extensão foi gerada por IA, tem somente 3 pares e não tem um par de controle. Além disso, o estilo dos textos é diferente do corpus-base (0,683 contra 0,951). Os pares também foram escolhidos depois que vimos os erros da validação. Tivemos poucos erros por par, usamos apenas um classificador e uma partição e não calculamos intervalo de confiança.

4. O que entregar em 03/10

- Este Instrumento M4 preenchido.
- Notebook final executável com a investigação M4 incorporada.
- Corpus final com extensão própria documentada.
- README final com pergunta, arquivos, execução, resultados, limites e uso de IA.

Não entregar relatório técnico separado. A apresentação será usada em 06/10 para a defesa.

5. Checklist final

- corpus-base bruto preservado
- extensão com pelo menos 80 exemplos e proveniência registrada
- trilha e questão justificadas por evidência do M16
- teste usado somente depois de congeladas as decisões
- nenhum ajuste feito depois de observar o teste
- acurácia, F1-macro, matriz e casos difíceis interpretados
- conclusão responde à questão e registra limites
- README, notebook, corpus e Instrumento M4 coerentes entre si