

M16 — Notebook de Comparação Controlada e Análise de Erros

LGN 2026.3 — Aula 6

versão final — M4 (Trilha A) com extensão e uso final da partição de teste

Objetivo

Comparar duas representações TF-IDF sob condições controladas, investigar diferenças de comportamento e analisar erros para formular uma hipótese e uma questão experimental preliminar.

Regra da aula: mudar uma variável por vez.

Teste: permanece preservado — sem `transform`, `predict`, métrica ou inspeção de rótulos.

Corpora v2: 5.000 registros por corpus, com 3.500 registros originalmente destinados ao treino, 750 à validação e 750 ao teste. Os 30 textos ausentes de cada corpus estão no treino e são removidos apenas para a modelagem, resultando em 3.470 textos utilizáveis no treino.

Extensão da Aula 8: as Partes A-E permanecem como registro da comparação em treino/validação. A nova Parte F deve ser executada somente depois que a configuração final estiver definida e registrada no M4.

1. Carregar o corpus e definir o alvo

Escolha o mesmo corpus usado no M15.

O M16 **não reconstrói o M15**: ele parte das mesmas convenções de arquivo, texto, alvo e `particao_recomendada`.

Pergunta: qual corpus e qual alvo estamos investigando?

```
In [1]: import pandas as pd
import matplotlib.pyplot as plt

from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score, f1_score, confusion_matrix, C

ARQUIVO = "P03_solicitacoes_atendimento_v2.csv" # troque por P01 ou P02,
MAPA_ALVO = {
```

```

    "P01_reclamacoes_assunto_v2.csv": "categoria_assunto",
    "P02_sentimento_avaliacoes_v2.csv": "sentimento",
    "P03_solicitacoes_atendimento_v2.csv": "setor_destino",
}

COL_TEXT0 = "texto"
COL_ALVO = MAPA_ALVO[ARQUIVO]

df = pd.read_csv(ARQUIVO, sep=";", encoding="utf-8-sig")

colunas_necessarias = {
    COL_TEXT0,
    COL_ALVO,
    "particao_recomendada",
}

faltantes = colunas_necessarias - set(df.columns)
assert not faltantes, f"Colunas ausentes no arquivo: {sorted(faltantes)}"

print("Corpus:", ARQUIVO)
print("Coluna de texto:", COL_TEXT0)
print("Alvo:", COL_ALVO)
print("Dimensões originais:", df.shape)
print("Estrutura mínima conferida.")

```

Corpus: P03_solicitacoes_atendimento_v2.csv
 Coluna de texto: texto
 Alvo: setor_destino
 Dimensões originais: (5000, 6)
 Estrutura mínima conferida.

2. Reproduzir o estado de entrada do M15

Preserve a divisão fornecida no corpus e remova somente registros sem texto para a modelagem.

Não refaça a divisão.

Cada corpus v2 contém originalmente **3.500 registros em treino, 750 em validação e 750 em teste**.

Os **30 textos ausentes** estão no treino; por isso, após a remoção desses registros, a modelagem usa **3.470 textos de treino**, mantendo validação e teste com 750 registros cada.

O teste continua apenas separado e contabilizado; não será transformado, previsto, avaliado ou inspecionado.

```

In [2]: CONTAGENS_ORIGINAIS = {
    "treino": 3500,
    "validacao": 750,
    "teste": 750,
}

contagens_originais = df["particao_recomendada"].value_counts().to_dict()

for particao, esperado in CONTAGENS_ORIGINAIS.items():

```

```

    observado = contagens_originais.get(particao, 0)
    print(f"{particao}: {observado} | esperado: {esperado}")
    assert observado == esperado, f"Contagem original de {particao} difer

ausentes_treino = df.loc[
    df["particao_recomendada"] == "treino", COL_TEXT0
].isna().sum()

ausentes_validacao = df.loc[
    df["particao_recomendada"] == "validacao", COL_TEXT0
].isna().sum()

ausentes_teste = df.loc[
    df["particao_recomendada"] == "teste", COL_TEXT0
].isna().sum()

print("\nTextos ausentes:")
print("Treino:", ausentes_treino)
print("Validação:", ausentes_validacao)
print("Teste:", ausentes_teste)

assert ausentes_treino == 30, "Esperavam-se 30 textos ausentes no treino.
assert ausentes_validacao == 0, "Não eram esperados textos ausentes na va
assert ausentes_teste == 0, "Não eram esperados textos ausentes no teste.

df_modelo = df.dropna(subset=[COL_TEXT0]).copy()

treino = df_modelo[df_modelo["particao_recomendada"] == "treino"].copy()
validacao = df_modelo[df_modelo["particao_recomendada"] == "validacao"].c
teste = df_modelo[df_modelo["particao_recomendada"] == "teste"].copy()

CONTAGENS_MODELAGEM = {
    "treino": 3470,
    "validacao": 750,
    "teste": 750,
}

print("\nApós remover somente textos ausentes:")
print("Treino utilizável:", len(treino), "| esperado:", CONTAGENS_MODELAG
print("Validação:", len(validacao), "| esperado:", CONTAGENS_MODELAGEM["v
print("Teste preservado:", len(teste), "| esperado:", CONTAGENS_MODELAGEM

assert len(treino) == CONTAGENS_MODELAGEM["treino"], "Contagem de treino
assert len(validacao) == CONTAGENS_MODELAGEM["validacao"], "Contagem de v
assert len(teste) == CONTAGENS_MODELAGEM["teste"], "Contagem de teste dif

print("\nPartições v2 conferidas. Não refaça o split.")

```

treino: 3500 | esperado: 3500
validacao: 750 | esperado: 750
teste: 750 | esperado: 750

Textos ausentes:
Treino: 30
Validação: 0
Teste: 0

Após remover somente textos ausentes:
Treino utilizável: 3470 | esperado: 3470
Validação: 750 | esperado: 750
Teste preservado: 750 | esperado: 750

Partições v2 conferidas. Não refaça o split.

3. Confirmar a comparação controlada

Nesta aula, vamos alterar **uma única variável experimental**:

- **Representação A:** TF-IDF com unigramas
- **Representação B:** TF-IDF com unigramas + bigramas

Permanecem fixos:

- mesmo corpus
- mesmo treino
- mesma validação
- mesmo alvo
- mesma `LogisticRegression`
- mesmas métricas

Variável experimental: `ngram_range`

```
In [3]: controle_experimental = {
        "corpus": ARQUIVO,
        "alvo": COL_ALVO,
        "classificador": "LogisticRegression(max_iter=1000, random_state=42)",
        "metricas": ["acuracia", "f1_macro", "matriz_de_confusao"],
        "variavel_experimental": "ngram_range",
        "representacao_A": "(1, 1)",
        "representacao_B": "(1, 2)",
    }
```

```
display(controle_experimental)
```

```
{'corpus': 'P03_solicitacoes_atendimento_v2.csv',
 'alvo': 'setor_destino',
 'classificador': 'LogisticRegression(max_iter=1000, random_state=42)',
 'metricas': ['acuracia', 'f1_macro', 'matriz_de_confusao'],
 'variavel_experimental': 'ngram_range',
 'representacao_A': '(1, 1)',
 'representacao_B': '(1, 2)'}
```

4. Preparar treino e validação

O aprendizado continua restrito ao treino.

- `fit_transform` será usado no treino
- `transform` será usado na validação
- nenhuma matriz de teste será criada

```
In [4]: y_treino = treino[COL_ALVO]
y_validacao = validacao[COL_ALVO]

assert treino[COL_ALVO].isna().sum() == 0
assert validacao[COL_ALVO].isna().sum() == 0
assert set(validacao[COL_ALVO]).issubset(set(treino[COL_ALVO]))

assert set(treino.index).isdisjoint(set(validacao.index))
assert set(treino.index).isdisjoint(set(teste.index))
assert set(validacao.index).isdisjoint(set(teste.index))

print("Treino e validação conferidos.")
print("Teste segue fora da representação e da previsão.")
```

Treino e validação conferidos.

Teste segue fora da representação e da previsão.

Parte A — Representação A

5. TF-IDF com unigramas

Pergunta: qual comportamento obtemos quando cada atributo textual deriva de termos individuais?

```
In [5]: vetorizador_A = TfidfVectorizer(ngram_range=(1, 1))

X_treino_A = vetorizador_A.fit_transform(treino[COL_TEXT0])
X_validacao_A = vetorizador_A.transform(validacao[COL_TEXT0])

print("Representação A – treino:", X_treino_A.shape)
print("Representação A – validação:", X_validacao_A.shape)
print("Número de atributos A:", X_treino_A.shape[1])
```

Representação A – treino: (3470, 288)

Representação A – validação: (750, 288)

Número de atributos A: 288

6. Treinar e avaliar o Modelo A

A configuração do classificador permanece fixa.

```
In [6]: modelo_A = LogisticRegression(max_iter=1000, random_state=42)
modelo_A.fit(X_treino_A, y_treino)

pred_A = modelo_A.predict(X_validacao_A)

acc_A = accuracy_score(y_validacao, pred_A)
f1_A = f1_score(y_validacao, pred_A, average="macro", zero_division=0)
```

```
print(f"Acurácia A: {acc_A:.3f}")
print(f"F1-macro A: {f1_A:.3f}")
```

Acurácia A: 0.935
F1-macro A: 0.934

7. Matriz de confusão — Modelo A


Observe o padrão dos erros.

Não interprete apenas o total de acertos.

```
In [7]: classes = list(modelo_A.classes_)

cm_A = confusion_matrix(y_validacao, pred_A, labels=classes)

disp_A = ConfusionMatrixDisplay(confusion_matrix=cm_A, display_labels=cla
disp_A.plot(cmap="Blues", xticks_rotation=45)
plt.title("Matriz de confusão — Representação A")
plt.tight_layout()
plt.show()
```



Parte B — Representação B

8. TF-IDF com unigramas + bigramas

Agora alteramos apenas `ngram_range`.

Pergunta: o comportamento do sistema muda quando a representação inclui combinações locais de duas palavras?

```
In [8]: vetorizador_B = TfidfVectorizer(ngram_range=(1, 2))

X_treino_B = vetorizador_B.fit_transform(treino[COL_TEXT0])
X_validacao_B = vetorizador_B.transform(validacao[COL_TEXT0])

print("Representação B – treino:", X_treino_B.shape)
print("Representação B – validação:", X_validacao_B.shape)
print("Número de atributos B:", X_treino_B.shape[1])
```

```
Representação B – treino: (3470, 2278)
Representação B – validação: (750, 2278)
Número de atributos B: 2278
```

9. Treinar e avaliar o Modelo B

O classificador continua exatamente igual ao da Representação A.

```
In [9]: modelo_B = LogisticRegression(max_iter=1000, random_state=42)
modelo_B.fit(X_treino_B, y_treino)

pred_B = modelo_B.predict(X_validacao_B)

acc_B = accuracy_score(y_validacao, pred_B)
f1_B = f1_score(y_validacao, pred_B, average="macro", zero_division=0)

print(f"Acurácia B: {acc_B:.3f}")
print(f"F1-macro B: {f1_B:.3f}")
```

```
Acurácia B: 0.960
F1-macro B: 0.959
```


10. Matriz de confusão — Modelo B

Compare com a matriz A:

- algum erro desapareceu?
- algum erro surgiu?
- alguma classe passou a ser confundida de outra forma?

```
In [10]: cm_B = confusion_matrix(y_validacao, pred_B, labels=classes)

disp_B = ConfusionMatrixDisplay(confusion_matrix=cm_B, display_labels=classes)
disp_B.plot(cmap="Blues", xticks_rotation=45)
plt.title("Matriz de confusão – Representação B")
plt.tight_layout()
plt.show()
```



Parte C — Comparar as evidências

11. Tabela comparativa

Acurácia e F1-macro são métricas de desempenho.

O número de atributos descreve a estrutura da representação — **não é uma métrica de desempenho**.

```
In [11]: comparacao = pd.DataFrame({
    "Representação": ["A — unigramas", "B — unigramas + bigramas"],
    "Acurácia": [acc_A, acc_B],
    "F1-macro": [f1_A, f1_B],
    "Nº atributos": [X_treino_A.shape[1], X_treino_B.shape[1]],
})

display(comparacao.round(3))
```

	Representação	Acurácia	F1-macro	Nº atributos
0	A — unigramas	0.935	0.934	288
1	B — unigramas + bigramas	0.960	0.959	2278

12. Comparar previsões exemplo a exemplo

Uma métrica global pode permanecer igual mesmo quando os erros mudam.

Vamos localizar os textos nos quais A e B produziram decisões diferentes.

```
In [12]: analise = validacao[[COL_TEXT0, COL_ALV0]].copy()
analise["pred_A"] = pred_A
analise["pred_B"] = pred_B
analise["A_correto"] = analise["pred_A"] == analise[COL_ALV0]
analise["B_correto"] = analise["pred_B"] == analise[COL_ALV0]
analise["A_diferente_B"] = analise["pred_A"] != analise["pred_B"]

divergencias = analise[analise["A_diferente_B"]].copy()

print("Exemplos em que A e B divergem:", len(divergencias))
display(divergencias.head(20))
```

Exemplos em que A e B divergem: 21

	texto	setor_destino	pred_A		pred
116	Estou com uma dúvida, quero confirmar o status...	secretaria_academica	biblioteca	secretaria_academ	
490	estou com uma dúvida, o link de recuperação de...	suporte_tecnico	financeiro	suporte_tecn	
673	Gente, preciso avaliar uma situação excepciona...	secretaria_academica	coordenacao	secretaria_academ	
934	Então, venho informar, quero entender uma cobr...	financeiro	coordenacao	finance	
1136	Preciso de informações sobre vencimento e juro...	financeiro	secretaria_academica	finance	
1851	Registro a seguinte situação: preciso conversa...	suporte_tecnico	coordenacao	suporte_tecn	
1921	O SISTEMA FECHA ANTES DE CONCLUIR A OPERAÇÃO, ...	suporte_tecnico	secretaria_academica	suporte_tecn	
2039	Preciso conversar sobre a organização da minha...	coordenacao	suporte_tecnico	coordenac	
2349	O link de recuperação de senha não chega. Além...	financeiro	suporte_tecnico	finance	
2374	Quero confirmar o status da matrícula; ao me...	biblioteca	secretaria_academica	bibliote	
2465	Preciso solicitar um histórico escolar, mas te...	secretaria_academica	suporte_tecnico	secretaria_academ	

	texto	setor_destino	pred_A		pred
2800	O sistema fecha antes de concluir a operação, ...	suporte_tecnico	suporte_tecnico		coordenac
3075	Venho informar, não consigo entrar no portal. ...	coordenacao	suporte_tecnico		coordenac
3306	Preciso de ajuda, o desconto da mensalidade não...	financeiro	biblioteca		finance
3628	Gente, preciso solicitar um histórico escolar,...	secretaria_academica	suporte_tecnico	secretaria_academ	
3910	por favor, bom dia, aparece uma mensagem de er...	suporte_tecnico	financeiro		suporte_tecn
4101	a página apresenta erro quando tento acessar; ...	secretaria_academica	suporte_tecnico	secretaria_academ	
4169	A página apresenta erro quando tento acessar. ...	financeiro	suporte_tecnico		finance
4272	alguém consegue me ajudar, preciso corrigir me...	secretaria_academica	financeiro	secretaria_academ	
4273	tenho um problema recorrente em uma turma e pr...	coordenacao	biblioteca		coordenac

13. Separar padrões de mudança

Vamos distinguir quatro situações:

1. A errou e B corrigiu
2. A acertou e B passou a errar
3. ambas erraram
4. ambas acertaram

O objetivo é investigar comportamento, não declarar automaticamente uma representação como melhor.

```
In [13]: A_errou_B_corrigiu = analyse[(analyse["A_correto"] == False) & (analyse["B_
A_acertou_B_errou = analyse[(analyse["A_correto"] == True) & (analyse["B_
ambas_erraram = analyse[(analyse["A_correto"] == False) & (analyse["B_cor
ambas_acertaram = analyse[(analyse["A_correto"] == True) & (analyse["B_co

resumo_mudancas = pd.DataFrame({
    "Situação": [
        "A errou / B corrigiu",
        "A acertou / B errou",
        "Ambas erraram",
        "Ambas acertaram",
    ],
    "Quantidade": [
        len(A_errou_B_corrigiu),
        len(A_acertou_B_errou),
        len(ambas_erraram),
        len(ambas_acertaram),
    ],
})

display(resumo_mudancas)
```

	Situação	Quantidade
0	A errou / B corrigiu	20
1	A acertou / B errou	1
2	Ambas erraram	29
3	Ambas acertaram	700

Parte D — Análise de erros

14. Inspeccionar casos concretos

Primeiro, verifique se a validação produziu erros ou divergências entre A e B.

Caminho A — existem erros ou divergências

Selecione 2 ou 3 casos que mereçam investigação.

Procure sinais como:

- ambiguidade entre classes
- texto muito curto
- informação insuficiente
- vocabulário compartilhado
- negação
- formulação incomum

- possível problema de rótulo

Caminho B — não existem erros nem divergências

Isso **também é um resultado experimental**.

Não invente erros e não conclua que a Representação B é superior. Registre:

Nesta validação, as duas representações produziram o mesmo comportamento observado e não forneceram erros suficientes para investigar a hipótese.

Depois responda:

Que tipo de exemplo novo seria necessário para colocar a hipótese à prova?

```
In [14]: erros_para_inspecao = analise[
    (analise["A_correto"] == False) | (analise["B_correto"] == False)
].copy()

print("Casos com pelo menos um erro:", len(erros_para_inspecao))
print("Divergências entre A e B:", len(divergencias))

if len(erros_para_inspecao) > 0:
    print("\nCaminho A — há erros para investigar.")
    candidatos_inspecao = erros_para_inspecao.copy()
    display(candidatos_inspecao.head(20))
else:
    print("\nCaminho B — não houve erros nesta validação.")
    print("Não invente casos. Registre a ausência de erros como evidência")
    print("Pergunta: que exemplos novos seriam necessários para testar me")
    candidatos_inspecao = erros_para_inspecao.copy()
```

Casos com pelo menos um erro: 50

Divergências entre A e B: 21

Caminho A — há erros para investigar.

	texto	setor_destino	pred_A	pred
116	Estou com uma dúvida, quero confirmar o status...	secretaria_academica	biblioteca	secretaria_academ
269	bom dia, preciso da segunda via do boleto. alé...	biblioteca	financeiro	finance
395	Só queria entender, não consigo entrar no port...	suporte_tecnico	coordenacao	coordenac
480	Quero conversar sobre pré-requisitos e sequênc...	coordenacao	financeiro	finance
490	estou com uma dúvida, o link de recuperação de...	suporte_tecnico	financeiro	suporte_tecn
553	Olá, o sistema fecha antes de concluir a opera...	biblioteca	suporte_tecnico	suporte_tecn
565	não consigo abrir o ambiente virtual; ao mesmo...	biblioteca	suporte_tecnico	suporte_tecn
673	Gente, preciso avaliar uma situação excepciona...	secretaria_academica	coordenacao	secretaria_academ
691	boa tarde, aparece uma mensagem de erro toda v...	financeiro	suporte_tecnico	suporte_tecn
818	Olá, meu nome saiu incorreto em um documento a...	secretaria_academica	biblioteca	bibliote
846	preciso de ajuda, uma disciplina não consta no...	secretaria_academica	coordenacao	coordenac

	texto	setor_destino	pred_A		pred
934	Então, venho informar, quero entender uma cobr...	financeiro	coordenacao		finance
1136	Preciso de informações sobre vencimento e juro...	financeiro	secretaria_academica		finance
1368	oi, preciso solicitar um histórico escolar alé...	suporte_tecnico	secretaria_academica	secretaria_academ	
1442	O comprovante foi enviado, mas o débito contin...	secretaria_academica	financeiro		finance
1628	Um livro devolvido ainda aparece comigo e tamb...	biblioteca	secretaria_academica	secretaria_academ	
1661	Quero orientação acadêmica antes de escolher a...	coordenacao	biblioteca		bibliote
1676	O comprovante foi enviado, mas o débito contin...	biblioteca	financeiro		finance
1851	Registro a seguinte situação: preciso conversa...	suporte_tecnico	coordenacao		suporte_tecn
1921	O SISTEMA FECHA ANTES DE CONCLUIR A OPERAÇÃO, ...	suporte_tecnico	secretaria_academica		suporte_tecn

15. Registrar os casos investigados — ou a ausência deles

Se houver erros

Selecione até 3 casos a partir da tabela anterior.

Os dados já conhecidos pelo notebook serão reaproveitados; você deverá

acrescentar apenas a **classificação do caso** e a **observação interpretativa**.

Se não houver erros

Não preencha casos fictícios. Registre explicitamente que a validação não ofereceu erros para análise e formule qual evidência nova seria necessária.

Evite conclusões fortes como “bigramas resolveram o problema”.

Prefira formulações condicionadas à validação observada.

```
In [15]: if len(candidatos_inspecao) > 0:
# Casos escolhidos: um de cada situação relevante (A errou/B corrigiu)
indices_escolhidos = [116, 269, 2800]

casos_analisados = candidatos_inspecao.loc[
    indices_escolhidos,
    [COL_TEXTO, COL_ALVO, "pred_A", "pred_B"]
].copy()

casos_analisados["tipo_de_caso"] = [
    "A errou / B corrigiu",
    "ambas erraram",
    "A acertou / B errou",
]
casos_analisados["observacao"] = [
    "Texto com dois pedidos (rematrícula + livro). O rótulo é secreta",
    "Texto com dois pedidos (boleto + base de periódicos). O rótulo é",
    "Texto com dois pedidos (sistema fecha + orientação sobre turma).",
]

display(casos_analisados)
else:
casos_analisados = pd.DataFrame(
    columns=[COL_TEXTO, COL_ALVO, "pred_A", "pred_B", "tipo_de_caso",
]

registro_sem_erros = {
    "resultado_observado": (
        "Nesta validação, não houve erros para analisar nas represent",
    ),
    "evidencia_nova_necessaria": "PREENCHER",
}

display(registro_sem_erros)
```

	texto	setor_destino	pred_A		pred_B	tipo
116	Estou com uma dúvida, quero confirmar o status...	secretaria_academica	biblioteca	secretaria_academica		/
269	bom dia, preciso da segunda via do boleto. alé...	biblioteca	financeiro	financeiro		
2800	O sistema fecha antes de concluir a operação, ...	suporte_tecnico	suporte_tecnico	coordenacao		A a

Parte E — Da observação à hipótese

16. Formular uma hipótese experimental

Uma hipótese é uma expectativa testável.

Exemplo de forma adequada:

“A inclusão de bigramas pode ajudar em textos nos quais combinações locais de palavras carregam informação relevante.”

Evite:

“Bigramas são melhores.”

```
In [16]: registro_investigacao = {
    "observacao_principal": (
        "Nesta validação, B (1,2) teve 0.960 de acurácia e 0.959 de F1-ma
        "Ambas as representações erraram 29 textos (50 com pelo menos um
        "ficaram em 3 dos 10 pares de setores: biblioteca×secretaria_acad
        "e coordenacao×suporte_tecnico (4). Nos casos inspecionados, os t
    ),
    "hipotese": (
        "Os casos mais difíceis podem se concentrar em alguns pares de se
        "secretaria_academica (com biblioteca e com financeiro) e coordena
        "por igual entre todos os pares."
    ),
    "questao_experimental_preliminar": (
        "Trilha A: quais pares de setores concentram os casos mais difíce
        "e o que esses pares têm em comum?"
    ),
    "evidencia_futura_necessaria": (
```

```

        "Mais exemplos, na extensão do corpus, com pedidos que envolvam o
        "incluindo textos com um único pedido e textos com dois pedidos,
        "Também convém conferir se o rótulo dos textos com dois pedidos é
    ),
}

display(registro_investigacao)

# Registre o tipo principal de evidência que motivou a investigação.
tipo_evidencia = "ambas erraram"
print("Tipo de evidência:", tipo_evidencia)

```

```

{'observacao_principal': 'Nesta validação, B (1,2) teve 0.960 de acurácia
e 0.959 de F1-macro, contra 0.935 e 0.934 de A (1,1). Ambas as representaç
ões erraram 29 textos (50 com pelo menos um erro). Na matriz de B, 14 dos
30 erros ficaram em 3 dos 10 pares de setores: biblioteca×secretaria_acade
mica (5), financeiro×secretaria_academica (5) e coordenacao×suporte_tecnic
o (4). Nos casos inspecionados, os textos difíceis trazem dois pedidos de
setores diferentes.',
'hipotese': 'Os casos mais difíceis podem se concentrar em alguns pares d
e setores, sobretudo os que envolvem secretaria_academica (com biblioteca
e com financeiro) e coordenacao×suporte_tecnico, e não se distribuir por i
gual entre todos os pares.',
'questao_experimental_preliminar': 'Trilha A: quais pares de setores conc
entram os casos mais difíceis do P03 (erros das duas representações) e o q
ue esses pares têm em comum?',
'evidencia_futura_necessaria': 'Mais exemplos, na extensão do corpus, com
pedidos que envolvam os pares de setores mais confundidos, incluindo texto
s com um único pedido e textos com dois pedidos, para verificar se a conce
ntração se mantém. Também convém conferir se o rótulo dos textos com dois
pedidos é consistente.'}
Tipo de evidência: ambas erraram

```

17. Síntese da comparação

Complete a síntese sem transformar diferença em superioridade automática.

Use formulações como:

- “Nesta validação, observamos que...”
- “A alteração de `ngram_range` produziu...”
- “Os principais erros concentraram-se em...”
- “Esse resultado ainda não permite concluir que...”

Tipo de evidência que motivou a investigação

Antes do registro final, identifique a evidência principal que originou a hipótese:

- divergência A×B
- A errou / B corrigiu
- A acertou / B errou
- ambas erraram

- ausência de diferença relevante
- outro caso difícil justificado

```
In [17]: registro_final_M16 = {
    "corpus": ARQUIVO,
    "variavel_experimental": "ngram_range",
    "A": {
        "configuracao": "(1, 1)",
        "acuracia": round(acc_A, 3),
        "f1_macro": round(f1_A, 3),
        "n_atributos": X_treino_A.shape[1],
    },
    "B": {
        "configuracao": "(1, 2)",
        "acuracia": round(acc_B, 3),
        "f1_macro": round(f1_B, 3),
        "n_atributos": X_treino_B.shape[1],
    },
    "divergencias_A_B": len(divergencias),
    "erros_para_inspecao": len(erros_para_inspecao),
    "interpretacao": "Nesta validação, a alteração de ngram_range de (1,1",
    "limitacao": "Este resultado ainda não permite concluir que bigramas",
    "hipotese": registro_investigacao["hipotese"],
    "questao_experimental_preliminar":
        registro_investigacao["questao_experimental_preliminar"],
    "evidencia_futura_necessaria":
        registro_investigacao["evidencia_futura_necessaria"],
}

display(registro_final_M16)
```

```
{'corpus': 'P03_solicitacoes_atendimento_v2.csv',
'variavel_experimental': 'ngram_range',
'A': {'configuracao': '(1, 1)',
'acuracia': 0.935,
'f1_macro': 0.934,
'n_atributos': 288},
'B': {'configuracao': '(1, 2)',
'acuracia': 0.96,
'f1_macro': 0.959,
'n_atributos': 2278},
'divergencias_A_B': 21,
'erros_para_inspecao': 50,
'interpretacao': 'Nesta validação, a alteração de ngram_range de (1,1) para (1,2) veio acompanhada de aumento de 0.025 na acurácia (750 exemplos) e de 20 correções contra 1 piora. Os erros restantes de ambas as representações concentram-se em textos com dois pedidos de setores diferentes.',
'limitacao': 'Este resultado ainda não permite concluir que bigramas são melhores em geral: vem de uma única validação de 750 exemplos, uma única semente e um único classificador, sem intervalo de confiança. B também tem cerca de 8 vezes mais atributos que A (2278 contra 288), o que não é métrica de desempenho. O corpus tem textos com estrutura repetitiva, e o rótulo dos textos com dois pedidos pode ser ambíguo.',
'hipotese': 'Os casos mais difíceis podem se concentrar em alguns pares de setores, sobretudo os que envolvem secretaria_academica (com biblioteca e com financeiro) e coordenacao_xsuporte_tecnico, e não se distribuir por igual entre todos os pares.',
'questao_experimental_preliminar': 'Trilha A: quais pares de setores concentram os casos mais difíceis do P03 (erros das duas representações) e o que esses pares têm em comum?',
'evidencia_futura_necessaria': 'Mais exemplos, na extensão do corpus, com pedidos que envolvam os pares de setores mais confundidos, incluindo textos com um único pedido e textos com dois pedidos, para verificar se a concentração se mantém. Também convém conferir se o rótulo dos textos com dois pedidos é consistente.'}
```

18. Verificação final de governança

Antes de encerrar, confirme:

- ☐ usei o mesmo corpus e as mesmas partições
- ☐ mantive o classificador fixo
- ☐ alterei apenas `ngram_range`
- ☐ comparei acurácia, F1-macro e matriz
- ☐ examinei exemplos concretos ou registrei justificadamente a ausência de erros para análise
- ☐ formulei uma hipótese
- ☐ formulei uma questão experimental preliminar
- ☐ não usei o teste para aprender, comparar ou decidir

Saída da Aula 6: comparação controlada + análise de erros + hipótese + questão experimental preliminar.

Ponte: preparar evidência nova na extensão do corpus, mantendo o teste preservado.

Parte E2 — Extensão do corpus (M4, Trilha A)

Questão experimental (Trilha A): quais pares de setores concentram os casos mais difíceis do P03 (erros das duas representações) e o que esses pares têm em comum?

Configuração congelada no M4: **B — TF-IDF unigramas + bigramas (1,2)**, sem novo `fit`. A extensão (`P03_extensao_TrilhaA.csv`) é um arquivo separado do corpus-base, com 120 exemplos gerados com apoio de IA (Claude); a revisão dos rótulos pelo grupo é registrada na coluna `revisado_pelo_grupo` do CSV. Esta parte **não usa o teste**.

```
In [18]: import numpy as np

ARQUIVO_EXT = "P03_extensao_TrilhaA.csv"
ext = pd.read_csv(ARQUIVO_EXT, sep=";", encoding="utf-8-sig")

assert len(ext) >= 80 and ext["id"].is_unique
assert ext[COL_TEXT0].isna().sum() == 0 and ext[COL_ALV0].isna().sum() == 0
assert set(ext[COL_ALV0]).issubset(set(treino[COL_ALV0]))
textos_base = set(pd.concat([treino, validacao])[COL_TEXT0])
assert not set(ext[COL_TEXT0]).intersection(textos_base), "A extensão não

# Apenas transform e predict: nenhum novo fit.
X_ext = vetorizador_B.transform(ext[COL_TEXT0])
ext["pred_B"] = modelo_B.predict(X_ext)
ext["correto"] = ext["pred_B"] == ext[COL_ALV0]

ext["tipo"] = np.where(
    ext["n_pedidos"] == 1, "um pedido",
    np.where(ext["marcador_prioridade"] == "sim", "dois pedidos, com marc
)

acc_ext = accuracy_score(ext[COL_ALV0], ext["pred_B"])
f1_ext = f1_score(ext[COL_ALV0], ext["pred_B"], average="macro", zero_div
print(f"Extensão ({len(ext)} exemplos) – acurácia: {acc_ext:.3f} | F1-mac
```

Extensão (120 exemplos) – acurácia: 0.683 | F1-macro: 0.677 | erros: 38

```
In [19]: resumo_tipo = ext.groupby("tipo")["correto"].agg(exemplos="size", acertos
resumo_par = ext.groupby("par_alvo")["correto"].agg(exemplos="size", acer

display(resumo_tipo)
display(resumo_par)
```

	exemplos	acertos	acuracia
tipo			
dois pedidos, com marcador	42	21	0.500
dois pedidos, sem marcador (ambíguo)	18	8	0.444
um pedido	60	53	0.883

	exemplos	acertos	acuracia
par_alvo			
biblioteca × secretaria_academica	40	27	0.675
coordenacao × suporte_tecnico	40	29	0.725
financeiro × secretaria_academica	40	26	0.650

```
In [20]: def pares_confundidos(real, previsto):
    """Conta os erros por par NÃO ordenado de setores (real × previsto)."""
    err = real != previsto
    pares = [" × ".join(sorted([r, p])) for r, p in zip(real[err], previsto[err])]
    return pd.Series(pares, dtype="object").value_counts()

pares_validacao_B = pares_confundidos(analise[COL_ALVO], analise["pred_B"])
pares_extensao_B = pares_confundidos(ext[COL_ALVO], ext["pred_B"])

comparacao_pares = (
    pd.concat([pares_validacao_B.rename("validação (750)"), pares_extensao_B.rename("extensão (120)"),
    ])
    .fillna(0).astype(int)
)
comparacao_pares["total"] = comparacao_pares.sum(axis=1)
comparacao_pares = comparacao_pares.sort_values("total", ascending=False)

display(comparacao_pares)
print("Erros na validação:", int(pares_validacao_B.sum()), "| erros na extensão:", int(pares_extensao_B.sum()))
```

	validação (750)	extensão (120)	total
financeiro × secretaria_academica	5	12	17
biblioteca × secretaria_academica	5	11	16
coordenacao × suporte_tecnico	4	10	14
biblioteca × suporte_tecnico	3	1	4
biblioteca × financeiro	2	2	4
coordenacao × secretaria_academica	2	2	4
biblioteca × coordenacao	3	0	3
coordenacao × financeiro	2	0	2
financeiro × suporte_tecnico	2	0	2
secretaria_academica × suporte_tecnico	2	0	2

Erros na validação: 30 | erros na extensão: 38

Parte F — Aula 8: aplicação final na partição de teste

19. Gate antes do teste final

Execute esta parte somente depois de encerrar as decisões de desenvolvimento e registrar no M4:

- questão experimental
- corpus/extensão usada na investigação
- preparação
- representação final
- classificador e configuração
- métricas que serão lidas

Regra: o resultado do teste serve para verificar e interpretar o pipeline final. Ele não deve ser usado para escolher uma nova configuração.

As células anteriores de validação **não devem ser substituídas nem apagadas.**

```
In [21]: # Escolha SOMENTE a configuração já definida antes de consultar o teste.
# Não altere esta escolha depois de observar o resultado do teste.
CONFIG_FINAL = "B" # use "A" ou "B" conforme a decisão registrada no M4

assert CONFIG_FINAL in {"A", "B"}, 'Use somente "A" ou "B".'

if CONFIG_FINAL == "A":
    vetorizador_final = vetorizador_A
    modelo_final = modelo_A
    nome_config_final = "A – TF-IDF unigramas (1,1)"
else:
    vetorizador_final = vetorizador_B
    modelo_final = modelo_B
    nome_config_final = "B – TF-IDF unigramas + bigramas (1,2)"

print("Configuração final congelada:", nome_config_final)
print("Próximo passo: aplicar esta configuração à partição de teste sem n
```

Configuração final congelada: B – TF-IDF unigramas + bigramas (1,2)
Próximo passo: aplicar esta configuração à partição de teste sem novo fit.

20. Aplicar o pipeline final ao conjunto de teste

Aqui o teste entra pela primeira vez na representação e na previsão.

Observe a diferença:

- usamos `transform`, porque o TF-IDF já foi ajustado no treino
- usamos `predict`, porque o classificador já foi ajustado no treino
- **não usamos `fit` nem `fit_transform` no teste**

```
In [22]: y_teste = teste[COL_ALVO]

assert teste[COL_TEXT0].isna().sum() == 0
assert teste[COL_ALVO].isna().sum() == 0
```

```

assert set(teste[COL_ALVO]).issubset(set(treino[COL_ALVO]))

X_teste_final = vetorizador_final.transform(teste[COL_TEXT0])
pred_teste_final = modelo_final.predict(X_teste_final)

print("Teste:", X_teste_final.shape)
print("Previsões produzidas:", len(pred_teste_final))
print("Nenhum novo fit foi realizado.")

```

Teste: (750, 2278)
 Previsões produzidas: 750
 Nenhum novo fit foi realizado.

21. Registrar as evidências quantitativas finais

As métricas abaixo descrevem o comportamento do **pipeline já definido** no conjunto de teste.

Na Aula 8, use:

- acurácia
- F1-macro
- precisão e recall por classe, quando forem úteis para responder à questão experimental

Não escolha uma nova configuração a partir destes valores.

```

In [23]: from sklearn.metrics import classification_report

acc_teste = accuracy_score(y_teste, pred_teste_final)
f1_teste = f1_score(y_teste, pred_teste_final, average="macro", zero_divi

print(f"Configuração final: {nome_config_final}")
print(f"Acurácia no teste: {acc_teste:.3f}")
print(f"F1-macro no teste: {f1_teste:.3f}")

relatorio_teste = classification_report(
    y_teste,
    pred_teste_final,
    labels=classes,
    output_dict=True,
    zero_division=0,
)

tabela_metricas_teste = (
    pd.DataFrame(relatorio_teste)
    .T
    .loc[classes, ["precision", "recall", "f1-score", "support"]]
)

display(tabela_metricas_teste.round(3))

```

Configuração final: B – TF-IDF unigramas + bigramas (1,2)
 Acurácia no teste: 0.951
 F1-macro no teste: 0.949

	precision	recall	f1-score	support
biblioteca	0.956	0.885	0.919	122.0
coordenacao	0.957	0.948	0.952	116.0
financeiro	0.927	0.994	0.959	178.0
secretaria_academica	0.971	0.949	0.960	178.0
suporte_tecnico	0.949	0.955	0.952	156.0

22. Matriz de confusão — teste final

Use a matriz para localizar onde os erros se concentram.


- linhas: classe real
- colunas: classe prevista
- diagonal: acertos
- fora da diagonal: erros

A matriz ajuda a interpretar o resultado; ela não abre uma nova rodada de ajuste.

```
In [24]: cm_teste = confusion_matrix(y_teste, pred_teste_final, labels=classes)

disp_teste = ConfusionMatrixDisplay(
    confusion_matrix=cm_teste,
    display_labels=classes,
)

disp_teste.plot(cmap="Blues", xticks_rotation=45)
plt.title(f"Matriz de confusão – teste final – {CONFIG_FINAL}")
plt.tight_layout()
plt.show()
```



23. Selecionar um caso difícil do teste para interpretação final

Agora é legítimo inspecionar erros do teste, porque as decisões já foram encerradas.

Use o caso para **interpretar e limitar a conclusão**, não para voltar e alterar o pipeline.

```
In [25]: analise_teste = teste[[COL_TEXTO, COL_ALVO]].copy()
analise_teste["pred_final"] = pred_teste_final
analise_teste["correto"] = analise_teste["pred_final"] == analise_teste[C

erros_teste = analise_teste[analise_teste["correto"] == False].copy()

print("Erros no teste:", len(erros_teste))

if len(erros_teste) > 0:
    display(erros_teste.head(20))
    print("Selecione um caso informativo para registrar no M4.")
else:
    print("Não houve erro observado no teste para esta configuração.")
    print("Registre a ausência de erros como resultado, sem extrapolar pa
```

Erros no teste: 37

	texto	setor_destino	pred_final	correto
176	Olá, minha senha não funciona. Além disso, pre...	biblioteca	suporte_tecnico	False
251	Quero negociar uma pendência financeira; ao me...	biblioteca	financeiro	False
340	preciso consultar uma pendência de empréstimo,...	biblioteca	suporte_tecnico	False
471	preciso da segunda via do boleto; ao mesmo tem...	secretaria_academica	financeiro	False
572	Pessoal, a devolução de um livro ainda não foi...	biblioteca	coordenacao	False
660	meu nome saiu incorreto em um documento acadêm...	secretaria_academica	suporte_tecnico	False
672	quero entender o procedimento de trancamento, ...	secretaria_academica	financeiro	False
850	Meu nome saiu incorreto em um documento acadêm...	coordenacao	secretaria_academica	False
888	Quero saber se um título está disponível. Além...	coordenacao	biblioteca	False
893	Então, minha matricula não aparece corretament...	secretaria_academica	suporte_tecnico	False
1260	preciso renovar um livro, mas tenho ainda outr...	biblioteca	suporte_tecnico	False
1792	Gente, por favor, tenho um problema recorrente...	biblioteca	coordenacao	False
1828	Preciso de informações sobre vencimento e juro...	biblioteca	financeiro	False
2196	PRECISO SOLICITAR UM HISTÓRICO ESCOLAR, MAS TE...	secretaria_academica	biblioteca	False
2233	queria uma orientação, fiz o pagamento e ainda...	biblioteca	financeiro	False
2258	boa tarde, o sistema fecha	biblioteca	suporte_tecnico	False

	texto	setor_destino	pred_final	correto
	antes de concluir a...			
2384	Solicito orientação: tenho um problema recorre...	suporte_tecnico	coordenacao	False
2470	quero confirmar o status da matrícula e tamb...	secretaria_academica	biblioteca	False
2534	n consigo entrar no portal e tbm meu pagamento...	suporte_tecnico	financeiro	False
2675	preciso renovar um livro, mas tenho ainda outr...	biblioteca	suporte_tecnico	False

Selecione um caso informativo para registrar no M4.

In [26]: `# Higiene de dados: a extensão não deve repetir textos do teste.
assert not set(ext[COL_TEXT0]).intersection(set(teste[COL_TEXT0])), "A ex
pares_teste_B = pares_confundidos(analise_teste[COL_ALV0], analise_teste[
display(pares_teste_B.to_frame("erros no teste"))
print("Erros no teste:", int(pares_teste_B.sum()))`

erros no teste	
biblioteca × suporte_tecnico	6
biblioteca × financeiro	6
financeiro × secretaria_academica	5
biblioteca × coordenacao	5
secretaria_academica × suporte_tecnico	4
coordenacao × secretaria_academica	3
financeiro × suporte_tecnico	3
biblioteca × secretaria_academica	2
coordenacao × suporte_tecnico	2
coordenacao × financeiro	1

Erros no teste: 37

24. Registro final para o M4

Complete a interpretação sem transformar o resultado em afirmação universal.

Uma redação defensável deve separar:

1. resultado observado
2. interpretação

3. conclusão em relação à questão experimental

4. limitação

```
In [27]: registro_teste_final = {
    "configuracao_final": nome_config_final,
    "acuracia_teste": round(acc_teste, 3),
    "f1_macro_teste": round(f1_teste, 3),
    "numero_erros_teste": len(erros_teste),
    "resultado_observado": (
        "No teste, B teve acurácia 0.951, F1-macro 0.949 e 37 erros em 75  

        "0 menor recall foi o de biblioteca (0.885). Todos os 37 erros es  

        "os textos sem esses marcadores foram todos acertados. Os 3 pares  

        "(financeiro×secretaria_academica 5, biblioteca×secretaria_academ  

        "Na extensão (120 exemplos), B teve acurácia 0.683: 0.883 com um  

    ),
    "interpretacao": (
        "Nesta validação e neste teste, a dificuldade do pipeline B está  

        "a concentração observada na validação (14 de 30 erros em 3 pares  

        "Os erros do teste se espalharam por vários pares, e biblioteca a  

        "Na extensão, a queda de acurácia ocorreu mesmo quando havia marc  

    ),
    "questao_experimental_respondida": (
        "Parcialmente. Os dados não sustentam que pares específicos conce  

        "A extensão foi construída apenas com os 3 pares da validação, en  

    ),
    "conclusao": (
        "enfraquecida – a hipótese de concentração nos pares da validação  

    ),
    "limitacao_principal": (
        "A extensão é sintética, gerada com apoio de IA e limitada a 3 pa  

        "Com 30 e 37 erros, as contagens por par são pequenas. Os 3 pares  

    ),
}

display(registro_teste_final)
```

```
{'configuracao_final': 'B – TF-IDF unigramas + bigramas (1,2)',
'acuracia_teste': 0.951,
'f1_macro_teste': 0.949,
'numero_erros_teste': 37,
'resultado_observado': 'No teste, B teve acurácia 0.951, F1-macro 0.949 e 37 erros em 750 textos (validação: 0.960 e 30 erros). O menor recall foi o de biblioteca (0.885). Todos os 37 erros estão em textos com marcadores de dois pedidos; os textos sem esses marcadores foram todos acertados. Os 3 pares mais confundidos na validação somaram 9 dos 37 erros do teste (financeiroxsecretaria_academica 5, biblioteca x secretaria_academica 2, coordenacao x suporte_tecnico 2). Na extensão (120 exemplos), B teve acurácia 0.683: 0.883 com um pedido, 0.500 com dois pedidos e marcador, 0.444 com dois pedidos sem marcador.',
'interpretacao': 'Nesta validação e neste teste, a dificuldade do pipeline B está nos textos com dois pedidos de setores diferentes, e não em pares específicos: a concentração observada na validação (14 de 30 erros em 3 pares) não se repetiu no teste (9 de 37, abaixo dos 30% esperados se todos os pares fossem iguais). Os erros do teste se espalharam por vários pares, e biblioteca aparece em 19 dos 37 (14 casos em que biblioteca era o rótulo real). Na extensão, a queda de acurácia ocorreu mesmo quando havia marcador de prioridade, o que sugere que TF-IDF com bigramas não usa esse marcador para decidir qual pedido é o principal.',
'questao_experimental_respondida': 'Parcialmente. Os dados não sustentam que pares específicos concentrem os casos mais difíceis; sustentam que os casos difíceis são os textos com dois pedidos. A extensão foi construída apenas com os 3 pares da validação, então não permite testar a concentração por par.',
'conclusao': 'enfraquecida – a hipótese de concentração nos pares da validação não se repetiu no teste; o que se repetiu nos dois conjuntos foi a dificuldade em textos com dois pedidos.',
'limitacao_principal': 'A extensão é sintética, gerada com apoio de IA e limitada a 3 pares; seu estilo difere do corpus-base (acurácia 0.683 contra 0.951 no teste), então parte da queda pode vir da mudança de escrita. Com 30 e 37 erros, as contagens por par são pequenas. Os 3 pares foram escolhidos depois de ver os erros da validação, o que infla a concentração observada (14 de 30). Um único classificador e uma única partição, sem intervalo de confiança.'}
```

25. Verificação final — depois do teste

Antes de encerrar:

- ☐ a configuração final já estava registrada antes de executar a Parte F
- ☐ não fiz `fit` nem `fit_transform` no teste
- ☐ não troquei A/B depois de observar o resultado do teste
- ☐ registrei acurácia e F1-macro do teste
- ☐ examinei precisão/recall por classe apenas quando pertinentes à questão
- ☐ li a matriz de confusão e selecionei um caso difícil quando existente
- ☐ usei o teste para interpretar, não para otimizar
- ☐ registrei conclusão e limitação no M4

Saída da Aula 8: resultado final do pipeline congelado + interpretação + caso difícil + conclusão + limitação.